

باسمه تعالی



فاز دوم پروژه‌ی درس مقدمه‌ی یادگیری ماشین

## مدل‌های گرافی و ماشین بولترمن

استاد درس

دکتر محمدحسین یاسائی میبدی

دانشکده‌ی مهندسی برق  
دانشگاه صنعتی شریف

پاییز ۱۴۰۳

آخرین مهلت تحویل:  
۱۵ بهمن ۱۴۰۳

## فهرست مطالب

۲	۱ بولتزمن امن
۲	۱.۱ نمونه برداری گیس
۳	۲.۱ به روز رسانی امن پارامترها
۷	۲ ماشین بولتزمن تمایزگر
۱۰	۳ نکات مهم

## ۱ بولتزمن امن

در فاز قبلی با ماشین بولتزمن آشنا شدید و نحوه استفاده از آن و به روز رسانی پارامترها را فراگرفتید. در این قسمت از فاز دوم پروژه، قصد داریم ماشین بولتزمن را به صورت امن پیاده سازی کنیم. فرض کنید که دو گروه A و B به ترتیب تعداد  $m_A$  و  $m_B$  نورون نمایان و پنهان دارند. این دو گروه می خواهند به طور مشترک ماشین بولتزمن را آموزش بدهند بطوریکه هیچکدام از گروه ها نباید از مقادیر نورون های یکدیگر مطلع بشوند. به همین دلیل از یک الگوریتم رمز گذاری استفاده می کنیم که در قسمت های بعدی با آن آشنا می شوید.

پرسش تئوری ۱. الگوریتم رمزگذاری ElGamal را کامل توضیح داده و روابط آن را بنویسید.

پرسش تئوری ۲. رمز گشایی جزئی را توضیح دهید.

### ۱.۱ نمونه برداری گیبس

همانطور که می دانید با نمونه برداری گیبس می توان مقادیر نورون های پنهان و نمایان را به روز رسانی کرد. الگوریتم به روز رسانی نورون ها به شرح زیر می باشد:

همانطور که می دانید که متغیرهای پنهان و نمایان با احتمال های زیر مقدار دهی می شوند:

$$h^{(n)} \sim \text{sigmoid}(W'.v^{(n)} + c)$$
$$v^{(n+1)} \sim \text{sigmoid}(W.h^{(n)} + b).$$

اما در این الگوریتم رمزگذاری، مقدار هر نورون را دقیقا برابر مقادیر گفته شده به عنوان پارامتر توزیع برنولی در عبارت قبل مقدار دهی می کنیم. حال برای به روز رسانی مقادیر نورون ها بدین صورت عمل می کنیم:

#### ۱. تقسیم داده ها بین دو گروه A و B

- داده ها به صورت عمودی تقسیم می شوند، به طوری که هر طرف فقط به بخشی از داده ها دسترسی دارد.
- به عنوان ورودی:

– گروه A مجموعه داده  $v_A^\circ = (v_1^\circ, v_2^\circ, \dots, v_{m_A}^\circ)$  را دارد.

– گروه B مجموعه داده  $v_B^\circ = (v_{m_A+1}^\circ, \dots, v_{m_A+m_B}^\circ)$  را دارد.

#### ۲. محاسبه مجموع وزن دار ورودی ها

- هر طرف ابتدا داده های قابل مشاهده خود را در ضرایب وزن  $w_{ij}$  ضرب کرده و مجموع مقادیر را محاسبه می کند. این کار شامل واحد های نمایان و پنهان می باشد.

#### ۳. رمزنگاری توسط گروه A

- گروه A تمام مقادیر مجموع وزن دار ورودی های خود را با تمامی حالات ممکن برای مجموع وزن دار ورودی های گروه B جمع می کند (هر کدام از این مجموع ها بایستی به عددی صحیح گرد بشود) و سپس از این مجموع تابع سیگموئید می گیرد و از حاصل تابع عدد تصادفی R را کم می کند.
- حال به ترتیب حالات ممکن برای مجموع وزن دار ورودی های گروه B این مقادیر را رمزگذاری کرده و به گروه B می فرستد.
- پیامی که گروه A در نهایت می فرستند به صورت رمز شده عبارات به صورت زیر می باشد:

$$\text{sigmoid} \left( \sum_{k \leq m_A} (w_{jk} v_k^\circ + c_k) + i \right) - R.$$

#### ۴. ارسال به گروه B و بازگشت اطلاعات رمزگشایی شده

- گروه B پیام متناظر با مجموع وزن دار ورودی های خودش را رمزگشایی کرده و این پیام را نویزی کرده و آن را به گروه A می فرستد.

#### ۵. رمزگشایی جزئی

- حال گروه A پیام نویزی شده ارسالی از گروه B را به صورت جزئی رمزگشایی کرده و دوباره برای گروه B آن را ارسال می کند.

#### ۶. رمزگشایی جزئی دیگر!

- حال گروه B پیامی که گروه A به صورت جزئی رمزگشایی کرده بود را دوباره رمزگشایی می کند. اینگونه گروه B پیام

$$\text{sigmoid} \left( \sum_{k \leq m_A} (w_{jk} v_k^\circ + c_k) + \sum_{m_A \leq k \leq m_A + m_B} (w_{jk} v_k^\circ + c_k) \right) - R$$

را خواهد داشت که این مقدار از گروه B و مقدار R از گروه A باعث می شود که مقدار اصلی برای به روز رسانی مقادیر ورودی ها بر اساس نمونه برداری گیبس به دست بیاید. یعنی

$$h_j^1 = \text{sigmoid} \left( \sum_{k \leq m_A} (w_{jk} v_k^\circ + c_k) + \sum_{m_A \leq k \leq m_A + m_B} (w_{jk} v_k^\circ + c_k) \right)$$

به همین ترتیب بقیه ورودی های نمایان و پنهان مقدار دهی می شوند.

برای درک بهتر الگوریتم، به کد قرار داده شده برای جمع امن دو عدد کمتر مساوی ۱۰ مراجعه کنید.<sup>۱</sup>

---

پرسش تئوری ۳. الگوریتمی مشابه آنچه برای محاسبه سیگموئید در بالا دید برای محاسبه ضرب دو عدد ارائه دهید، فرض کنید پارتی A عدد M را میداند و پارتی B عدد N را میداند. و میخواهند MN را محاسبه کنند.

---

#### ۲۰.۱ به روز رسانی امن پارامترها

میدانیم در ماشین بولتزمن گرادیان از رابطه زیر بدیت می آید (با فرض یک مرحله برای گیبس سمپلینگ):

$$(\langle v_i^\circ h_j^\circ \rangle_{\text{data}} - \langle v_i^1 h_j^1 \rangle_{\text{model}})$$

که برای مسئله دو پارتی ما میتوان آنرا به شکل زیر نوشت:

$$h^\circ = h_1^\circ + h_r^\circ, \quad V^1 = V_1^1 + V_r^1, \quad \text{و} \quad h^1 = h_1^1 + h_r^1,$$

$$V^\circ h^\circ - V^1 h^1 = V^\circ (h_1^\circ + h_r^\circ) - (V_1^1 + V_r^1) (h_1^1 + h_r^1).$$

$$V^\circ h^\circ - V^1 h^1 = V^\circ h_1^\circ + V^\circ h_r^\circ - V_1^1 h_1^1 - V_1^1 h_r^1 - V_r^1 h_1^1 - V_r^1 h_r^1.$$

که در آن عدد بالا نشان دهنده مرحله گیبس و عدد پایین نشان دهنده طرفی است که داده متعلق به آن است. حال الگوریتمی ارائه میدهیم که با استفاده از آن میتوان به صورت امن عبارت بالا را محاسبه کرد.

مرحله ۱: مقداردهی اولیه

- وزن ها ( $W$ )، بایاس لایه ورودی ( $b$ ) و بایاس لایه مخفی ( $c$ ) را با مقادیر کوچک تصادفی مقداردهی اولیه کنید.

- مقادیر اولیه  $W$ ،  $b$ ، و  $c$  را با هر دو طرف  $A$  و  $B$  به اشتراک بگذارید.

مرحله ۲: نمونه‌گیری گیبس  
هدف این مرحله نمونه‌گیری ایمن از لایه‌های مخفی و مرئی با استفاده از یک مرحله نمونه‌گیری گیبس است.

مرحله ۱.۲: محاسبه احتمالات لایه مخفی  $(h_j^\circ)$

• طرف A:

$$\sum_{k \leq m_A} (w_{jk} V_k^\circ + c_k).$$

• طرف B:

$$\sum_{m_A < k \leq m_A + m_B} (w_{jk} V_k^\circ + c_k).$$

• هر دو طرف: با استفاده از الگوریتم ۱، تابع سیگموئید برای کل مقدار محاسبه می‌شود:

$$h_j^\circ = h_{j1}^\circ + h_{j2}^\circ,$$

که  $h_{j2}^\circ$  و  $h_{j1}^\circ$  سهم‌های تصادفی مربوط به طرف A و B هستند.

مرحله ۲.۲: محاسبه احتمالات لایه مرئی  $(v_i^1)$

• طرف A:

$$\sum_{k \leq m_A} (w_{ik} h_k^\circ + b_k).$$

• طرف B:

$$\sum_{m_A < k \leq m_A + m_B} (w_{ik} h_k^\circ + b_k).$$

• هر دو طرف: با استفاده از الگوریتم ۱، تابع سیگموئید برای کل مقدار محاسبه می‌شود:

$$v_i^1 = v_{i1}^1 + v_{i2}^1,$$

که  $v_{i2}^1$  و  $v_{i1}^1$  سهم‌های تصادفی مربوط به طرف A و B هستند.

مرحله ۳.۲: محاسبه احتمالات لایه مخفی  $(h_j^1)$

• طرف A:

$$\sum_{k \leq m_A} (w_{jk} v_k^1 + c_k).$$

• طرف B:

$$\sum_{m_A < k \leq m_A + m_B} (w_{jk} v_k^1 + c_k).$$

• هر دو طرف: با استفاده از الگوریتم ۱، تابع سیگموئید برای کل مقدار محاسبه می‌شود:

$$h_j^1 = h_{j1}^1 + h_{j2}^1.$$

مرحله ۳: به‌روزرسانی وزن‌ها

مرحله ۱.۳: محاسبه مقادیر لازم برای به‌روزرسانی وزن‌ها

• طرف A محاسبه می‌کند:

$$V_1^\circ h_1^\circ, \quad V_1^1 h_1^1$$

• طرف B محاسبه می‌کند:

$$V_2^\circ h_2^\circ, \quad V_2^1 h_2^1$$

این مقادیر سهم‌های محلی هر طرف از ارتباطات مثبت و منفی برای به‌روزرسانی وزن‌ها هستند.

مرحله ۲.۳: محاسبه ایمن ضرب‌های متقابل

برای محاسبه ترم‌های متقابل (مانند  $V_1^\circ h_1^\circ$  و  $V_2^\circ h_2^\circ$ )، هر دو طرف از الگوریتم ضرب استفاده می‌کنند:

• ارتباطات مثبت ( $V_1^\circ h_2^\circ$ ):

- طرفین از الگوریتم ضرب برای محاسبه ایمن ضرب  $V_1^\circ h_2^\circ$  استفاده می‌کنند.
- این محاسبه منجر به دو سهم تصادفی می‌شود:

$$r_{11}^\circ, \quad r_{12}^\circ,$$

به‌طوری‌که:

$$r_{11}^\circ + r_{12}^\circ = V_1^\circ h_2^\circ.$$

• ارتباطات مثبت ( $V_2^\circ h_1^\circ$ ):

- به‌طور مشابه، طرفین  $V_2^\circ h_1^\circ$  را با استفاده از الگوریتم ضرب محاسبه می‌کنند.
- این محاسبه منجر به دو سهم تصادفی می‌شود:

$$r_{21}^\circ, \quad r_{22}^\circ,$$

به‌طوری‌که:

$$r_{21}^\circ + r_{22}^\circ = V_2^\circ h_1^\circ.$$

• ارتباطات منفی ( $V_1^\circ h_1^\circ$ ):

- طرفین از الگوریتم ضرب برای محاسبه  $V_1^\circ h_1^\circ$  استفاده می‌کنند، و به مقادیر زیر می‌رسند:

$$r_{11}^{\circ\prime}, \quad r_{12}^{\circ\prime},$$

به‌طوری‌که:

$$r_{11}^{\circ\prime} + r_{12}^{\circ\prime} = V_1^\circ h_1^\circ.$$

• ارتباطات منفی ( $V_2^\circ h_2^\circ$ ):

- به‌طور مشابه، طرفین  $V_2^\circ h_2^\circ$  را محاسبه می‌کنند، و به مقادیر زیر می‌رسند:

$$r_{21}^{\circ\prime}, \quad r_{22}^{\circ\prime},$$

به‌طوری‌که:

$$r_{21}^{\circ\prime} + r_{22}^{\circ\prime} = V_2^\circ h_2^\circ.$$

مرحله ۳.۳: محاسبه گرادیان برای به‌روزرسانی وزن‌ها

• اگر طرف  $A$  واحد مرئی  $V_1^\circ$  را داشته باشد:

- طرف  $A$  محاسبه می‌کند:

$$G_A = V_1^\circ h_1^\circ + r_{11}^\circ - V_1^\circ h_1^{\circ\prime} - r_{11}^{\circ\prime} - r_{12}^{\circ\prime}.$$

- طرف  $B$  محاسبه می‌کند:

$$G_B = r_{12}^\circ - V_2^\circ h_2^\circ - r_{12}^{\circ\prime} - r_{22}^{\circ\prime}.$$

- طرف  $B$ ، مقدار  $G_B$  را به طرف  $A$  می‌فرستد.

- طرف  $A$ ، مقادیر  $G_A + G_B$  را برای محاسبه گرادیان کامل جمع می‌کند:

$$G = G_A + G_B.$$

• اگر طرف  $B$  واحد مرئی  $V_2^\circ$  را داشته باشد:

- فرآیند مشابه انجام می‌شود و طرف  $B$  گرادیان را ترکیب می‌کند.

مرحله ۴.۳: به‌روزرسانی وزن‌ها

- پس از محاسبه گرادیان  $G$ ، طرف  $A$  (یا  $B$ ) وزن‌ها را با استفاده از نزول گرادیان به‌روزرسانی می‌کند:

$$w_{\text{new}} = w_{\text{old}} - \eta G,$$

که در آن  $\eta$  نرخ یادگیری است.

مرحله ۵.۳: به‌روزرسانی بایاس‌ها

- با استفاده از روش مشابه، بایاس‌ها ( $b$  و  $c$ ) به‌روزرسانی می‌شوند:

$$b_{\text{new}} = b_{\text{old}} - \eta \Delta b,$$

$$c_{\text{new}} = c_{\text{old}} - \eta \Delta c.$$

مرحله ۶.۳: بازگشت مقادیر به‌روزرسانی‌شده

- مقادیر به‌روزرسانی‌شده وزن ( $W$ ) و بایاس ( $b, c$ ) به هر دو طرف بازگردانده می‌شوند.

مرحله ۴: تکرار تا همگرایی

- نمونه‌گیری گیبس و به‌روزرسانی وزن‌ها را برای تمام نمونه‌های آموزشی تکرار کنید.
- تکرار کنید تا شرط توقف (مثلاً تعداد دوره‌های ثابت یا همگرایی وزن‌ها) برقرار شود.


---

پرسش شبیه‌سازی ۰.۱ با مجموعه داده MNIST و به کارگیری ماشین بولتزمن امن به عنوان استخراج کننده داده، تسک طبقه بندی را انجام بدهید و عملکرد آن را با حالت ماشین بولتزمن ساده مقایسه کنید.

---

## ۲ ماشین بولتزمن تمایزگر

در قسمت قبل شما با مدل بولتزمن به عنوان یک مدل مولد ساده ولی قدرتمند آشنا شدید. حال، می‌خواهیم از قابلیت‌های این مدل، و به طول کل مدل‌های بر پایه انرژی برای طبقه بندی داده‌ها استفاده کنیم. در این بخش با مدل‌های بولتزمن تمایزگر (DRBM) <sup>۲</sup> آشنا خواهید شد. این مدل‌ها برخلاف RBM های استاندارد که برای یادگیری توزیع مشترک داده‌ها  $p(x, y)$  طراحی شده‌اند، به طور خاص برای یادگیری توزیع شرطی بین داده‌ها و برچسب‌های آن‌ها  $p(y|x)$  استفاده می‌شوند.



شکل ۱: ماشین بولتزمن تمایزگر

مدل بولتزمن تمایزگر با تغییر در تابع انرژی RBM استاندارد ساخته می‌شود. در DRBM برچسب داده  $y$  به عنوان بخشی از لایه ورودی مدل (لایه قابل مشاهده) اضافه می‌شود. تابع انرژی در DRBM به شکل زیر تعریف می‌شود:

$$E(x, y, h) = - \sum_i \sum_j W_{ij} x_i h_j - \sum_i b_i x_i - \sum_j c_j h_j - \sum_k d_k y_k$$

و در نهایت خواهیم داشت  $p(x, y, h) \propto \exp(-E(x, y, h))$ . برای باینری کردن برچسب‌ها و استفاده بهینه (و منطقی) از آنها، اینجا نیز  $y$  به صورت One-hot Encoding از برچسب‌ها استفاده می‌شود. هدف طبقه بندی مناسب است. در نتیجه به دنبال بیشینه درست نمایی  $p(y|x) \propto \exp(-\mathcal{F}(x, y))$  هستیم. این توزیع بیانگر احتمال تخصیص یک برچسب خاص  $y$  به داده ورودی  $x$  و بیانگر انرژی آزاد است.

پرسش تئوری ۰۴: با توجه به تابع انرژی در نظر گرفته شده  $E(x, y, h)$ ، به پرسش‌های زیر پاسخ دهید.

۱. توزیع مشترک  $p(y, x)$  را محاسبه کنید.

۲. توزیع شرطی  $p(y|x)$  را محاسبه کنید.

۳. مسئله بهینه سازی لگاریتم درست نمایی  $p(y, x)$  و گرادینان آن را به صورت ریاضی بنویسید. آیا این مسئله با روش‌های مرسوم بهینه سازی قابل حل است؟ اگر بله توضیح دهید، اگر نه برای آن راه حلی ارائه دهید.

۴. مسئله بهینه سازی لگاریتم درست نمایی  $p(y|x)$  و گرادینان آن را به صورت ریاضی بنویسید. آیا این مسئله با روش‌های مرسوم بهینه سازی قابل حل است؟ اگر بله توضیح دهید، اگر نه برای آن راه حلی ارائه دهید.

۵. یک نمایش تابع انرژی آزاد  $\mathcal{F}(x, y)$  را بدست بیاورید.

در مرحله اول، میتوان برای تولید  $p(y|x)$  از  $p(y, x)$  استفاده کنیم. همانطور که انتظار می‌رود، یادگیری  $p(y, x)$  همانند یادگیری مدل بولتزمن عادی است، و به رابطه زیر منجر می‌شود.

$$\frac{\partial \log p(y_*, x_*)}{\partial \theta} = -\mathbb{E}_{h|y_*, x_*} \left[ \frac{\partial}{\partial \theta} E(y_*, x_*, h) \right] + \mathbb{E}_{h, y, x} \left[ \frac{\partial}{\partial \theta} E(y, x, h) \right].$$

برای این کار از الگوریتم یادگیری ماشین بولتزمن با استفاده از Contrastive Divergence استفاده می‌کنیم. و سپس با استفاده از مدل نهایی،  $p(y|x)$  را برای تمامی کلاس‌ها محاسبه کرده و طبقه بندی را میتوان انجام داد.

<sup>۲</sup> Discriminative Restricted Boltzmann Machine



---

**Algorithm 1** Training update for RBM over  $(y, \mathbf{x})$   
using Contrastive Divergence

---

**Input:** training pair  $(y_i, \mathbf{x}_i)$  and learning rate  $\lambda$   
 % Notation:  $a \leftarrow b$  means  $a$  is set to value  $b$   
 %  $a \sim p$  means  $a$  is sampled from  $p$   
  
 % Positive phase  
 $y^0 \leftarrow y_i, \mathbf{x}^0 \leftarrow \mathbf{x}_i, \hat{\mathbf{h}}^0 \leftarrow \text{sigm}(\mathbf{c} + W\mathbf{x}^0 + U y^0)$   
  
 % Negative phase  
 $\mathbf{h}^0 \sim p(\mathbf{h}|y^0, \mathbf{x}^0), y^1 \sim p(y|\mathbf{h}^0), \mathbf{x}^1 \sim p(\mathbf{x}|\mathbf{h}^0)$   
 $\hat{\mathbf{h}}^1 \leftarrow \text{sigm}(\mathbf{c} + W\mathbf{x}^1 + U y^1)$   
  
 % Update  
**for**  $\theta \in \Theta$  **do**  
 $\theta \leftarrow \theta - \lambda \left( \frac{\partial}{\partial \theta} E(y^0, \mathbf{x}^0, \hat{\mathbf{h}}^0) - \frac{\partial}{\partial \theta} E(y^1, \mathbf{x}^1, \hat{\mathbf{h}}^1) \right)$   
**end for**

---

شکل ۲: الگوریتم یادگیری ماشین بولتزمن با برچسب

پرسش شبیه‌سازی ۰۲. داده‌های MNIST را بارگذاری کرده و آن‌ها را به حالت باینری تبدیل کنید (مثلاً با اعمال یک آستانه روی شدت پیکسل‌ها)، سپس با آموزش یک RBM توزیع  $p(y, x)$  را با استفاده از الگوریتم شکل ۲ تخمین بزنید. بعد از آموزش مدل، طبقه بندی مدلی نهایی را با استفاده از  $p(y|x)$  انجام داده و دقت آن را گزارش کنید.

اگر دقت ما فقط روی طبقه بندی باشد، میتوانیم بجای بهینه سازی  $p(y, x)$  و تولید یک مدل مولد با یادگیری توزیع داده، فقط  $p(y|x)$  را مورد توجه قرار بدهیم و آن را بهینه کنیم.

پرسش تئوری ۰۵. رابطه زیر را اثبات کنید.

$$\frac{\partial \log p(y|x)}{\partial \theta} = \sum_j \sigma(o_{yj}(x)) \cdot \frac{\partial o_{yj}(x)}{\partial \theta} - \sum_{y', j} \sigma(o_{y'j}(x)) \cdot \frac{\partial o_{y'j}(x)}{\partial \theta}$$

که در آن  $o_{yj}(x) = c_j + \sum_k W_{jk}x_k + U_{jy}$  میباشد، در نتیجه میتوانیم محاسبه دقیق گرادیان انجام دهیم.

با توجه به اینکه  $|y| = K$  که در آن  $K$  تعداد کلاس است، بهینه سازی یک DRBM بسیار ساده تر از بهینه سازی RBM های معمول است. همانطور که میتوان دید، DRBM ها شباهت بسیاری با شبکه های Feedforward دارند و مزیت اضافی وجود یک مدل بر پایه انرژی، در ذات RBM ای آنها به ما قابلیت های تولید داده جدید، به صورت کنترل شده می دهد. حال میتوانیم توانایی های این مدل را برای طبقه بندی ارزیابی کنیم.

پرسش شبیه‌سازی ۰۳. داده‌های MNIST را بارگذاری کرده و آن‌ها را به حالت باینری تبدیل کنید (مثلاً با اعمال یک آستانه روی شدت پیکسل‌ها)، سپس با آموزش یک DRBM توزیع  $p(y|x)$  را تخمین بزنید. بعد از آموزش مدل، دقت طبقه بندی مدلی نهایی را گزارش کنید.

به صورت کلی، برای یادگیری یک مدل تمایز دهنده از  $\mathcal{L}_{\text{disc}}$  و برای یادگیری یک مدل مولد از  $\mathcal{L}_{\text{gen}}$  میتوان استفاده کرد.

$$\mathcal{L}_{\text{disc}}(\mathcal{D}) = - \sum_{i=1}^{|\mathcal{D}|} \log p(y_i | x_i), \quad \mathcal{L}_{\text{gen}}(\mathcal{D}) = - \sum_{i=1}^{|\mathcal{D}|} \log p(y_i, x_i)$$

یادگیری مدل با استفاده از  $\mathcal{L}_{\text{disc}}$  ساده تر است، ولی از توانایی های یک مدل مولد دیگر استفاده نمیکنیم و فقط به طور مستقیم قدرت طبقه بندی را بهینه میکنیم.  $\mathcal{L}_{\text{gen}}$  برای بهینه سازی یک مدل مولد مناسب است، ولی سخت بودن بهینه سازی آن، و لحاظ نشدن مستقیم قدرت طبقه بندی ممکن است به بهترین قدرت طبقه بندی منجر نشود. به صورت کلی پیدا شده است که برای مجموعه داده های کوچک تر، روش یادگیری یک توزیع مولد مناسب تر است، و برای مجموعه داده های بزرگ، روش یادگیری یک مدل تمایزگر مناسب تر است. به صورت کلی میتوانیم یک روش هیبرید استفاده کنیم، که در عمل میتواند مفید باشد:

$$\mathcal{L}_{\text{hybrid}}(\mathcal{D}) = \mathcal{L}_{\text{disc}}(\mathcal{D}) + \alpha \mathcal{L}_{\text{gen}}(\mathcal{D}).$$

---

پرسش شبیه سازی ۰۴. باری دیگر، یادگیری را با روش هیبرید و  $\alpha \in \{0.1, 0.5, 1\}$  انجام دهید، و با استفاده از  $p(y|x)$  طبقه بندی را انجام داده، و دقت نهایی را گزارش کنید.

---

پرسش تئوری ۰۶. نتیجه نهایی یادگیری و دقت طبقه بندی را برای تمامی مدل های قبلی گزارش کرده و مقایسه کنید، آیا نتایج آن مطابق انتظار شماست؟

---

در تمامی مراحل، با استفاده از یک مجموعه داده  $\mathcal{D}_{\text{sup}} = \{x_i, y_i\}$  یک مدل تمایزگر طراحی کردیم که قابلیت مدل سازی مولد را بر اساس یک تابع انرژی دارد. با این حال، جمع آوری داده های برجسب دار در بسیاری از موارد هزینه بر است و معمولاً حجم این نوع داده ها محدود است. در مقابل، داده های بدون برجسب  $\mathcal{D}_{\text{unsup}} = \{x_i\}$  به طور گسترده تر در دسترس هستند و می توان از آن ها برای بهبود یادگیری مدل بهره برد.

---

پرسش تئوری ۰۷. آیا میتوان در کنار داده های برجسب دار  $\mathcal{D}_{\text{sup}}$  از داده های  $\mathcal{D}_{\text{unsup}}$  نیز استفاده کرد؟ به صورت دقیق تا ما دنبال یک تابع هدف نهایی به صورت زیر هستیم.

$$\mathcal{L}_{\text{semi-sup}}(\mathcal{D}_{\text{sup}}, \mathcal{D}_{\text{unsup}}) = \mathcal{L}_{\text{sup}}(\mathcal{D}_{\text{sup}}) + \beta \mathcal{L}_{\text{unsup}}(\mathcal{D}_{\text{unsup}})$$

یک پیشنهاد مناسب برای  $\mathcal{L}_{\text{unsup}}$  ارائه دهید، و جزئیات بهینه سازی آن را توضیح دهید.

---

پرسش شبیه سازی ۰۵. (امتیازی) باری دیگر، فرآیند یادگیری را به روش شبه نظارتی انجام دهید، به طوری که:

- مقدار  $n$  یکی از مقادیر  $\{0.1N, 0.5N, N\}$  باشد.
- مجموعه نظارتی  $\mathcal{D}_{\text{sup}}$  شامل  $n$  داده اول از مجموعه MNIST در نظر گرفته شود.
- مجموعه غیرنظارتی  $\mathcal{D}_{\text{unsup}}$  شامل  $N - n$  داده باقی مانده باشد.

پس از یادگیری مدل، طبقه بندی را با استفاده از  $p(y|x)$  انجام داده و دقت نهایی را گزارش کنید.

---

## ۳ نکات مهم

لطفاً به نکات زیر دقت کنید:

۱. پروژه شامل دو فاز خواهد بود.
۲. پروژه را میتوانید به صورت انفرادی یا به شکل گروه های دو نفره انجام دهید. دقت کنید چه به شکل انفرادی و چه به صورت گروهی باید تمام بخش های پروژه را انجام دهید و انجام انفرادی آن امتیاز اضافه ای برای شما نخواهد داشت.
۳. دو فاز این پروژه در مجموع ۲ تا ۳ نمره از نمره درس را تشکیل می دهند.
۴. پس از پایان پروژه یک روز برای تحویل حضوری پروژه در نظر گرفته می شود و باید کد ها و خروجی های خود را در حضور دستیاران آموزشی ارائه دهید و به پرسش های دستیاران پاسخ دهید. دقت کنید که تمام اعضای گروه باید به تمام بخش های پروژه مسلط باشند. در نهایت برای تمام اعضای گروه یک نمره در نظر گرفته خواهد شد.
۵. برای فاز نخست پروژه میتوانید حداکثر ۳ روز تاخیر مجاز استفاده نمایید اما به دلیل وجود ددلاین ثبت نمرات ددلاین فاز دوم پروژه سخت خواهد بود و امکان استفاده از تاخیر برای آن وجود ندارد.
۶. فاز دوم شامل یک سوال امتیازی می باشد که حداکثر ۰.۲ نمره اضافی خواهد داشت.
۷. تمامی شبیه سازی ها باید با کمک زبان Python انجام شود. همچنین مجاز هستید از تمام کتابخانه هایی که در طول تمرین ها از آنها استفاده کرده اید مانند numpy, scipy و pytorch استفاده نمایید اما دقت کنید پیاده سازی الگوریتم ها باید توسط شما انجام شده باشد و نمیتوانید از کتابخانه هایی که الگوریتم را به صورت آماده پیاده سازی کرده اند استفاده نمایید.
۸. تحویل پروژه به صورت گزارش و کدهای نوشته شده است. گزارش باید شامل پاسخ پرسش ها، تصاویر و نمودارها و نتیجه گیری های لازم باشد. در نهایت یک فایل شامل کد ها و یک گزارش به فرمت pdf را در سامانه CW آپلود نمایید. آپلود کردن پروژه توسط یکی از اعضای گروه کافی میباشد.
۹. اگر برای پاسخ به پرسش ها، از منبعی (کتاب، مقاله، سایت و...) کمک گرفته اید، حتماً به آن ارجاع دهید.
۱۰. در صورت مشاهده ی تقلب، نمره ی هردو فرد صفر منظور خواهد شد.
۱۱. مسئول پروژه آقای سلیمان بیگی میباشد و در صورت داشتن مشکلاتی در گروه بندی، زمان تحویل حضوری و ... به ایشان (@amirr62a) پیام دهید.
۱۲. در صورت داشتن پرسش در بخش ۱ به @amirrezazameni یا @Mahdi\_h721 و در بخش ۲ به @BornaKhodabandeh پیام دهید.

موفق باشید!