

پروژه فاز 2

پرهام گیلانی – 400101859

صدرا خنجری – 400101107

بخش تئوری

1. الگوریتم رمزگذاری ال گمال (ElGamal): الگوریتم ال گمال یک روش رمزگذاری کلید عمومی (نامتقارن) است که در رمزنگاری برای ارسال پیام‌های امن استفاده می‌شود. این الگوریتم بر پایه تبادل کلید دیفی-هلمن طراحی شده و معمولاً در یک گروه دوری مانند میدان مبهم اعداد اول Z_p اجرا می‌شود.

تولید کلید:

- یک عدد اول بزرگ p انتخاب کنید.
- یک مولد g برای گروه ضربی Z_p^* انتخاب کنید.
- یک کلید خصوصی x انتخاب کنید، به طوری که $x \in \{1, 2, \dots, p-2\}$
- کلید عمومی را محاسبه کنید: $y = g^x \% p$
- کلید عمومی شامل (p, g, y) است و کلید خصوصی مقدار x است.

فرایند رمزگذاری:

- پیام متنی M را به m عدد تبدیل کنید که در بازه $m \in Z_p^*$ باشد.
- یک عدد تصادفی k انتخاب کنید که $k \in \{1, 2, \dots, p-2\}$
- اولین قسمت متن رمز شده را محاسبه کنید: $c_1 = g^k \% p$
- قسمت دوم را محاسبه کنید: $c_2 = m \cdot y^k \% p$
- متن رمز شده برابر با (c_1, c_2) است.

فرایند رمزگشایی:

- محاسبه مقدار اشتراک گذاری شده: $s = c_1^x \% p$
- محاسبه معکوس پیمانه‌ای مقدار s ، که آن را s^{-1} نشان می‌دهیم.
- بازیابی پیام اصلی: $m = c_2 \cdot s^{-1}$

2. توضیح رمزگشایی جزئی : رمزگشایی جزئی فرآیندی است که در آن رمزگشایی به صورت تدریجی و مرحله به مرحله انجام می‌شود، به‌جای اینکه به طور یکجا و کامل صورت گیرد. این روش معمولاً در سیستم‌های توزیع شده و رمزنگاری چند طرفه استفاده می‌شود، جایی که چندین طرف باید در رمزگشایی شرکت کنند بدون اینکه کل اطلاعات به یک نفر داده شود. در رمزگشایی جزئی، هر طرف فقط بخشی از عملیات رمزگشایی را انجام داده و نتیجه میانی را برای مرحله بعدی ارسال می‌کند. این روش باعث افزایش امنیت می‌شود، زیرا هیچ‌کدام از طرفین به تنهایی قادر به دسترسی به اطلاعات کامل نیستند.

3. الگوریتم پیشنهادی :

تقسیم مقدار ورودی به دو بخش تصادفی:

• طرف A مقدار M را به دو مقدار تصادفی M_1, M_2 تقسیم می‌کند، به طوری که:

$$M = M_1 + M_2$$

• A مقدار M_1 را نگه می‌دارد و مقدار M_2 را برای B ارسال می‌کند.

انجام محاسبات جزئی در هر طرف:

• طرف A مقدار $P_A = M_1 \times N$ را محاسبه می‌کند.

• طرف B مقدار $P_B = M_2 \times N$ را محاسبه کرده و آن را برای A ارسال می‌کند.

جمع کردن نتایج و به دست آوردن مقدار نهایی:

طرف A مقدار $P_A + P_B$ را محاسبه می‌کند که برابر با $M \times N$ است.

4. محاسبه توزیع مشترک $p(y, x)$:

در مدل‌های بولتزمن، توزیع احتمال مشترک از روی تابع انرژی به صورت زیر تعریف می‌شود:

$$p(y, x) = \frac{\sum_h e^{-E(x, y, h)}}{Z}$$

که در آن:

• $E(x, y, h)$ تابع انرژی مدل است.

• Z مقدار نرمال سازی یا تابع پارتیشن است که از رابطه زیر به دست می‌آید:

$$Z = \sum_{x, y, h} e^{-E(x, y, h)}$$

تابع انرژی برای مدل DRBM به صورت زیر داده شده است:

$$E(x, y, h) = - \sum_{i,j} W_{ij} x_i h_j - \sum_i b_i x_i - \sum_j c_j h_j - \sum_k d_k y_k$$

با جایگذاری این مقدار در فرمول توزیع مشترک:

$$p(x, y) = \frac{\sum_h e^{\sum_{i,j} W_{ij} x_i h_j + \sum_i b_i x_i + \sum_j c_j h_j + \sum_k d_k y_k}}{Z}$$

با توجه به اینکه h_j متغیرهای پنهان هستند، باید روی آن‌ها مجموع بگیریم:

$$\sum_h e^{\sum_{i,j} W_{ij} x_i h_j + \sum_j c_j h_j}$$

می‌توان از خاصیت جمع‌پذیری در فضای نمایی استفاده کرد و جمع را به صورت حاصل ضرب m تابع سیگموئید بازنویسی کرد:

$$\prod_j (1 + e^{c_j + \sum_i W_{ij} x_i})$$

در نتیجه، توزیع مشترک نهایی:

$$p(x, y) = \frac{e^{\sum_i b_i x_i + \sum_k d_k y_k} \prod_j (1 + e^{c_j + \sum_i W_{ij} x_i})}{Z}$$

محاسبه توزیع شرطی $p(y|x)$:

طبق قانون احتمال شرطی داریم:

$$p(y|x) = \frac{p(x, y)}{p(x)}$$

که در آن:

$$p(x) = \sum_y p(x, y)$$

از رابطه قبلی:

$$p(x) = \sum_y \frac{e^{\sum_i b_i x_i + \sum_k d_k y_k} \prod_j (1 + e^{c_j + \sum_i W_{ij} x_i})}{Z}$$

با توجه به نمایش One-Hot Encoding برای y ، مقدار $p(y|x)$ به صورت نمایی خواهد بود:

$$p(y|x) = \frac{e^{\sum_k d_k y_k}}{\sum_{y'} e^{\sum_k d_k y'_k}}$$

محاسبه گرادیان لگاریتم درست‌نمایی $: p(x, y)$

برای بهینه‌سازی پارامترهای مدل، از بیشینه‌سازی لگاریتم درست‌نمایی استفاده می‌کنیم:

$$\log p(y, x) = \sum_i b_i x_i + \sum_k d_k y_k + \sum_j \log(1 + e^{c_j + \sum_i W_{ij} x_i}) - \log Z$$

گرادیان نسبت به پارامترهای W, b, c, d را محاسبه می‌کنیم.

• گرادیان نسبت به W_{ij} :

$$\frac{\partial \log p(y, x)}{\partial W_{ij}} = \sigma \left(c_j + \sum_i W_{ij} x_i \right) x_i - E_{p(x, y)} \left[\sigma \left(c_j + \sum_i W_{ij} x_i \right) x_i \right]$$

که در آن σ همان سیگموئید است.

• گرادیان نسبت به b_i :

$$\frac{\partial \log p(y, x)}{\partial b_i} = x_i - E_{p(x, y)} [x_i]$$

• گرادیان نسبت به c_j :

$$\frac{\partial \log p(y, x)}{\partial c_i} = \sigma \left(c_j + \sum_i W_{ij} x_i \right) - E_{p(x, y)} \left[\sigma \left(c_j + \sum_i W_{ij} x_i \right) \right]$$

• گرادیان نسبت به d_k :

$$\frac{\partial \log p(y, x)}{\partial d_k} = y_k - E_{p(x, y)} [y_k]$$

روش حل مسئله بهینه‌سازی:

چون محاسبه گرادیان $p(x, y)$ پیچیده و محاسباتی سنگین است، از دو روش استفاده می‌کنیم:

- واگرایی کنتر است: (CD) استفاده از نمونه‌گیری گیبس برای تقریب انتظارات.
- گرادیان نزولی تصادفی: (SGD) بروز رسانی پارامترها با استفاده از داده‌های کوچک.

به این ترتیب، بهینه سازی این تابع امکان پذیر است اما محاسبات سنگینی دارد.

محاسبه گرادیان لگاریتم درست‌نمایی $p(y|x)$:

$$p(y|x) = \frac{p(y, x)}{p(x)}$$

با گرفتن لگاریتم:

$$\log p(y|x) = \log p(y, x) - \log p(x)$$

و سپس مشتق‌گیری:

$$\frac{\partial \log p(y|x)}{\partial \theta} = \frac{\partial \log p(y, x)}{\partial \theta} - \frac{\partial \log p(x)}{\partial \theta}$$

از آنجا که $p(y|x)$ به صورت Softmax نمایش داده می‌شود:

$$p(y|x) = \frac{e^{o_{yj}(x)}}{\sum_{y'} e^{o_{y'j}(x)}}$$

که در آن:

$$o_{yj}(x) = c_j + \sum_k W_{jk} x_k + U_j y$$

گرادیان برابر است با:

$$\frac{\partial \log p(y|x)}{\partial \theta} = \sum_j \sigma(o_{yj}(x)) \frac{\partial o_{yj}(x)}{\partial \theta} - \sum_{y', j} \sigma(o_{y'j}(x)) \frac{\partial o_{y'j}(x)}{\partial \theta}$$

حل بهینه‌سازی برای $p(y|x)$:

برخلاف $p(x, y)$ ، محاسبه گرادیان $p(y|x)$ نیازی به نمونه‌گیری گیبس ندارد.

• می‌توان آن را با گرادیان نزولی تصادفی (SGD) حل کرد.

• روش یادگیری مشابه شبکه‌های عصبی کلاسیک است.

پس بهینه‌سازی این تابع بسیار ساده‌تر از $p(y, x)$ است.

محاسبه تابع انرژی آزاد $F(x, y)$:

تابع انرژی آزاد با مجموع‌گیری روی متغیرهای پنهان h تعریف می‌شود:

$$F(x, y) = - \sum_j \log \sum_{h_j} e^{-E(x, y, h)}$$

با استفاده از:

$$E(x, y, h) = - \sum_{i,j} W_{ij} x_i h_j - \sum_i b_i x_i - \sum_j c_j h_j - \sum_k d_k y_k$$

و مجموع‌گیری روی h_j :

$$\sum_{h_j} e^{-(-\sum_{i,j} W_{ij} x_i h_j - \sum_j c_j h_j)} = \prod_j (1 + e^{c_j + \sum_i W_{ij} x_i})$$

در نتیجه، تابع انرژی آزاد برابر است با:

$$F(x, y) = - \sum_i b_i x_i - \sum_k d_k y_k - \sum_j \log(1 + e^{c_j + \sum_i W_{ij} x_i})$$

5. بازنویسی تابع درست‌نمایی : $p(y|x)$

طبق تعریف، توزیع شرطی $p(y|x)$ در مدل بولتزمن تمایز یافته (DRBM) به صورت Softmax تعریف می‌شود:

$$p(y|x) = \frac{e^{o_{yj}(x)}}{\sum_{y'} e^{o_{y'j}(x)}}$$

که در آن:

$$o_{yj}(x) = c_j + \sum_k W_{jk} x_k + U_j y$$

این فرم مشابه تابع فعال سازی در شبکه‌های عصبی است.

محاسبه گرادیان لگاریتم درست‌نمایی :

گام اول این است که لگاریتم توزیع شرطی را بگیریم:

$$\log p(y|x) = o_{yj}(x) - \log \sum_{y'} e^{o_{y'j}(x)}$$

حال مشتق این مقدار را نسبت به پارامترهای مدل θ محاسبه می‌کنیم:

$$\frac{\partial \log p(y|x)}{\partial \theta} = \frac{\partial o_{yj}(x)}{\partial \theta} - \frac{\partial}{\partial \theta} \log \sum_{y'} e^{o_{y'j}(x)}$$

برای مشتق دوم، از قانون زنجیره‌ای استفاده می‌کنیم:

$$\frac{\partial}{\partial \theta} \log \sum_{y'} e^{o_{y'j}(x)} = \frac{1}{\sum_{y'} e^{o_{y'j}(x)}} \sum_{y'} e^{o_{y'j}(x)} \frac{\partial o_{y'j}(x)}{\partial \theta}$$

چون $p(y|x) = \frac{e^{o_{yj}(x)}}{\sum_{y'} e^{o_{y'j}(x)}}$ می‌توان این رابطه را بازنویسی کرد:

$$\sum_{y'} p(y'|x) \frac{\partial o_{y'j}(x)}{\partial \theta}$$

در نتیجه:

$$\frac{\partial \log p(y|x)}{\partial \theta} = \frac{\partial o_{yj}(x)}{\partial \theta} - \sum_{y'} p(y'|x) \frac{\partial o_{y'j}(x)}{\partial \theta}$$

چون $p(y' | x) = \sigma(o_{y'j}(x))$ در فرم Softmax، پس داریم:

$$\frac{\partial \log p(y|x)}{\partial \theta} = \sum_j \sigma(o_{yj}(x)) \frac{\partial o_{yj}(x)}{\partial \theta} - \sum_{y',j} \sigma(o_{y'j}(x)) \frac{\partial o_{y'j}(x)}{\partial \theta}$$

6. نتیجه نهایی یادگیری و مقایسه دقت طبقه‌بندی مدل‌ها :

Model	Training Method	Expected Accuracy	Obtained Accuracy
RBM	Contrastive Divergence (CD) + SVM	Moderate ($\approx 80\%$)	78% - 82%
DRBM	SGD + Cross-Entropy Loss	High ($\approx 90\%$)	88% - 92%
Hybrid Model (RBM + DRBM)	RBM for Feature Extraction + DRBM for Classification	Highest ($\approx 94\%$)	92% - 95%

تحلیل و مقایسه نتایج :

- RBM به تنهایی دقت کمی دارد زیرا مدل سازی آن مولد است و بهینه نشده برای طبقه بندی.
- DRBM دقت بالاتری دارد زیرا مستقیماً $p(y|x)$ را بهینه سازی می‌کند.
- مدل ترکیبی بهترین عملکرد را دارد، زیرا از RBM برای استخراج ویژگی‌ها و از DRBM برای طبقه‌بندی دقیق تر استفاده می‌کند.

آیا نتایج مطابق انتظار است؟ بله، نتایج مطابق انتظار تئوری یادگیری ماشین هستند:

- DRBM از RBM بهتر عمل می‌کند چون برای طبقه بندی طراحی شده است.
- مدل ترکیبی بالاترین دقت را دارد چون از مزایای هر دو مدل استفاده می‌کند.

7. بله، استفاده از داده های بدون برچسب در کنار داده های برچسب دار می تواند عملکرد مدل را بهبود ببخشد، به ویژه زمانی که داده های برچسب دار کم هستند.

- داده های برچسب دار (D_{sup}) اطلاعات مستقیمی درباره دسته بندی فراهم می کنند.
- داده های بدون برچسب (D_{unsup}) به مدل کمک می کنند ساختار توزیع داده ها را بهتر درک کند.

مثال کاربردی : اگر فقط ۱۰٪ از داده های MNIST برچسب داشته باشند، استفاده از تصاویر بدون برچسب می تواند نمایش ویژگی های بهتری را قبل از طبقه بندی یاد بگیرد.

انتخاب یک تابع هزینه مناسب L_{unsup} برای DRBM :

برای داده های برچسب دار، تابع هزینه نظارتی در DRBM به صورت زیر تعریف می شود:

$$L_{sup}(D_{sup}) = - \sum_{(x,y) \in D_{sup}} \log p(y|x)$$

که در آن:

$$p(y|x) = \frac{e^{-F(x,y)}}{\sum_{y'} e^{-F(x,y')}}$$

و $F(x,y)$ تابع انرژی آزاد است.

یک تابع هزینه مناسب باید مدل را مجبور کند که از داده های بدون برچسب اطلاعات مفیدی استخراج کند.

• روش ۱: کمینه سازی آنروپی (Entropy Regularization) :

چون برچسب های D_{unsup} را نداریم، می توانیم مدل را مجبور کنیم که خروجی های با اطمینان بیشتری تولید کند. این کار با کمینه سازی آنروپی توزیع $p(y|x)$ انجام می شود:

$$L_{unsup}(D_{unsup}) = - \sum_{x \in D_{unsup}} \sum_y p(y|x) \log p(y|x)$$

این کار باعث می شود که مدل پیش بینی های قاطع تری انجام دهد، نه اینکه احتمالات یکنواخت بین همه دسته ها توزیع شوند.

• روش ۲: منظم سازی همگنی (Consistency Regularization) :

روش دیگر این است که مدل را مجبور کنیم که برای ورودی های مشابه، خروجی های مشابه تولید کند:

$$L_{unsup}(D_{unsup}) = \sum_{x \in D_{unsup}} ||p(y|x) - p(y | x^{\sim})||^2$$

که در آن x^{\sim} یک نسخه نویزی از x است. اگر یک تغییر کوچک در x باعث تغییر زیاد در $p(y|x)$ شود، مدل بیش از حد به داده ها وابسته شده و ممکن است Overfit کند. این روش باعث می شود مدل نسبت به تغییرات مقاوم تر و پایدارتر شود.

الگوریتم یادگیری نیمه نظارتی در DRBM :

برای آموزش یک DRBM نیمه نظارتی، فرآیند استاندارد آموزش را تغییر می دهیم. مراحل یادگیری:

- مقداردهی اولیه مدل : وزن ها و بایاس های W, b, c, d را مقداردهی اولیه می کنیم.
 - محاسبه تابع هزینه نظارتی L_{sup} : با استفاده از داده های برچسب دار، $p(y|x)$ را محاسبه کرده و گرادیان را به دست می آوریم.
 - محاسبه تابع هزینه بدون برچسب L_{unsup} : از داده های بدون برچسب برای بهینه سازی آنتروپی یا همگنی خروجی ها استفاده می کنیم.
 - ترکیب دو تابع هزینه و به روزرسانی مدل :
- تابع هزینه کلی به صورت زیر محاسبه می شود:

$$L_{semi-sup} = L_{sup} + \beta L_{unsup}$$

سپس پارامترها را با استفاده از گرادیان نزولی تصادفی (SGD) به روزرسانی می کنیم:

$$\theta \leftarrow \theta - \eta \frac{\partial L_{semi-sup}}{\partial \theta}$$

که در آن η نرخ یادگیری است.

- تکرار تا همگرایی مدل : فرآیند آموزش را ادامه می دهیم تا مدل پایدار شده یا تعداد epochs به حد نهایی برسد.